

تشخیص ناهنجاری شبکه مبتنی بر یادگیری ماشین: طراحی، پیاده‌سازی و ارزیابی

نویسندگان: پیلار شومر، آلبرتو دل ریو، خاویر سرانو و همکاران

دانشگاه: پلی‌تکنیک مادرید (ETSIT)

تاریخ انتشار: دسامبر ۲۰۲۴

ژورنال: AI (MDPI)

۱. چکیده (Abstract)

در دهه گذشته، شناسایی داده‌های پرت (Outliers) در محیط‌های پیچیده شبکه اهمیت دوچندانی یافته است. این مقاله یک سیستم تشخیص ناهنجاری شبکه (NAD) را معرفی می‌کند که از ترکیب روش‌های یادگیری نظارت‌شده و نظارت‌نشده استفاده می‌کند. مدل‌های پیشنهادی با استفاده از مجموعه‌داده‌های واقعی آموزش دیده و با معیارهای دقت، فراخوانی و F1-Score ارزیابی شده‌اند. نتایج نشان داد که مدل SVM با دقت ۹۶.۵٪ و جنگل تصادفی (Random Forest) با دقت ۹۴.۳٪ بهترین عملکرد را دارند. همچنین از مقادیر SHAP برای تفسیرپذیری مدل و شناسایی عوامل کلیدی ناهنجاری استفاده شده است.

۲. مقدمه (Introduction)

با گسترش اینترنت اشیا (IoT) و زیرساخت‌های ابری، شبکه‌های مدرن با حجم عظیمی از داده‌ها روبرو هستند. سیستم‌های تشخیص نفوذ سنتی که بر پایه امضا (Signature-based) کار می‌کنند، در برابر حملات جدید (Zero-day) ناتوان هستند. یادگیری ماشین (Machine Learning) به دلیل توانایی در یادگیری الگوهای رفتاری نرمال و شناسایی انحرافات، به عنوان راهکار جایگزین معرفی شده است. این تحقیق بر روی ناهنجاری‌های نقطه‌ای (Point Anomalies) تمرکز دارد که در آن یک مورد داده‌ای نسبت به کل مجموعه داده، ناهنجار تلقی می‌شود.

۳. روش‌شناسی (Materials and Methods)

۳.۱. محیط شبکه و جمع‌آوری داده

برای آزمایش، از ابزار EVE-NG جهت شبیه‌سازی یک شبکه سازمانی استفاده شد.

- تولید ترافیک: از نرم‌افزار FFmpeg برای پخش جریان‌های ویدیویی استفاده شد تا ترافیک واقعی شبیه‌سازی شود.

- کاوشگر داده (Probe) یک اسکرپت پایتون برای استخراج ویژگی‌های شبکه در فواصل زمانی ۱۵ ثانیه‌ای طراحی شد.

۳.۲. ویژگی‌های استخراج شده (Features)

ویژگی‌های کلیدی شامل موارد زیر است:

- **Throughput** نرخ عبور: (مقدار داده منتقل شده در ثانیه).
- **Latency** تاخیر: (زمان لازم برای انتقال بسته).
- **Jitter** لرزش: (تغییرات در زمان تاخیر).
- **Packet Loss** اتلاف بسته: (درصد بسته‌های گم شده).
- **Congestion** احتقان: (میزان پر شدن بافرها در گره‌های شبکه).

۴. تحلیل داده‌ها و پیش‌پردازش (Data Analysis)

۴.۱. تحلیل آماری

نتایج نشان داد که احتقان (Congestion) همبستگی مستقیمی با اتلاف بسته ($r=0.45$) دارد.

۴.۲. تجسم‌سازی با t-SNE

از الگوریتم t-SNE برای کاهش ابعاد و نمایش خوشه‌های داده استفاده شد. این تحلیل نشان داد که داده‌های ناهنجار (High Congestion) به طور مشخصی از ترافیک نرمال جدا می‌شوند.

۵. پیاده‌سازی یادگیری ماشین (ML Implementation)

۵.۱. یادگیری نظارت‌نشده (Unsupervised)

از الگوریتم Dynp برای تشخیص نقاط تغییر (Change Points) استفاده شد. این روش بدون نیاز به برچسب‌گذاری، زمان‌هایی که رفتار شبکه تغییر می‌کند (مانند افت ناگهانی پهنای باند) را شناسایی کرد.

۵.۲. یادگیری نظارت‌شده (Supervised)

سه مدل اصلی مورد مقایسه قرار گرفتند:

۱. رگرسیون لجستیک (LR) به عنوان مدل پایه با دقت ۹۱.۲٪.
۲. جنگل تصادفی (RF) با توانایی بالا در مدیریت داده‌های غیرخطی و دقت ۹۴.۳٪.
۳. ماشین بردار پشتیبان (SVM) با دقت ۹۶.۵٪ که بالاترین دقت عددی را داشت.

۶. تفسیرپذیری و اهمیت ویژگی‌ها (SHAP)

یکی از بخش‌های نوآورانه این مقاله، استفاده از SHAP (SHapley Additive exPlanations) است. این تحلیل نشان داد که:

- **احتقان (Congestion):** مهم‌ترین عامل در شناسایی ناهنجاری است.
- نرخ عبور (Throughput) در رتبه دوم اهمیت قرار دارد.

این یافته به مدیران شبکه کمک می‌کند تا بدانند در زمان بروز بحران، کدام شاخص را باید در اولویت بررسی قرار دهند.

۷. نتیجه‌گیری (Conclusion)

این پژوهش نشان داد که ترکیب روش‌های آماری و یادگیری ماشین می‌تواند با دقت بسیار بالایی ناهنجاری‌های شبکه را شناسایی کند. مدل‌های پیشنهادی نه تنها ناهنجاری را تشخیص می‌دهند، بلکه به دلیل استفاده از SHAP، علت بروز ناهنجاری را نیز تبیین می‌کنند. پیشنهاد می‌شود در کارهای آینده از شبکه‌های عصبی عمیق (Deep Learning) برای تحلیل ترافیک رمزنگاری شده استفاده شود.

۸. مراجع (References)

این مقاله از ۶۸ مرجع علمی معتبر از جمله کارهای چاولا، ناکاشیما و مقالات قبلی در حوزه امنیت شبکه استفاده کرده است.

FedMADE: یادگیری فدرال مقاوم برای تشخیص نفوذ در شبکه‌های IoT با استفاده از روش تجمع پویا

نویسندگان: شیوا سون، پراگیا شارما، کینچوکو نوودو و همکاران دانشگاه ویرجینیا تک، ایالات متحده آمریکا
(Virginia Tech) تاریخ: اگوست ۲۰۲۴ منتشر شده در arXiv

۱. چکیده (Abstract)

گسترش سریع دستگاه‌های اینترنت اشیا (IoT) نگرانی‌های امنیتی شدیدی را ایجاد کرده است. مدل‌های سنتی یادگیری ماشین نیازمند ارسال داده‌ها به سرور مرکزی هستند که حریم خصوصی را به خطر می‌اندازد. یادگیری فدرال (Federated Learning) با نگه داشتن داده‌ها در دستگاه‌های محلی این مشکل را حل می‌کند. با این حال، ناهمگونی داده‌ها و عدم توازن کلاس‌های حمله (Imbalance) چالش‌های بزرگی هستند. در این مقاله، روش FedMADE معرفی می‌شود که یک متد تجمع پویا است و دستگاه‌ها را بر اساس الگوهای ترافیکی و توزیع حملات خوشه‌بندی می‌کند تا دقت تشخیص حملات اقلیت را افزایش دهد.

۲. مقدمه (Introduction)

دستگاه‌های IoT به دلیل قدرت پردازشی کم، اهداف جذابی برای مهاجمان سایبری هستند. حملات بات‌نت (Botnet) و منع سرویس (DDoS) از جمله تهدیدات اصلی هستند. یادگیری فدرال به دستگاه‌ها اجازه می‌دهد بدون اشتراک‌گذاری داده‌های خام، یک مدل جهانی (Global Model) بسازند. اما مشکل اینجاست که یک دستگاه ممکن است فقط ترافیک "عادی" داشته باشد و دستگاه دیگر تحت حمله "Mirai" باشد؛ این تفاوت توزیع داده باعث ضعیف شدن مدل نهایی می‌شود.

۳. بررسی ادبیات و کارهای مرتبط (Related Work)

این بخش به بررسی سیستم‌های تشخیص نفوذ (IDS) و الگوریتم‌های تجمع در یادگیری فدرال مانند FedAvg می‌پردازد. نویسندگان توضیح می‌دهند که روش‌های موجود نمی‌توانند به خوبی با داده‌های غیر مستقل و غیر هم‌توزیع (Non-IID) مقابله کنند و نرخ تشخیص (DR) آن‌ها در حملات نادر بسیار پایین است.

۴. طراحی سیستم (The FedMADE Design)

۴.۱. خوشه‌بندی پویا

FedMADE دستگاه‌ها (Clients) را بر اساس شباهت در پارامترهای مدل محلی خوشه‌بندی می‌کند.

- دستگاه‌هایی که رفتارهای ترافیکی مشابهی دارند در یک گروه قرار می‌گیرند.
- این کار باعث می‌شود دانش مربوط به یک نوع حمله خاص در بین دستگاه‌های مشابه تقویت شود.

۴.۲. وزن‌دهی مبتنی بر کیفیت

برخلاف FedAvg که فقط بر اساس حجم داده وزن‌دهی می‌کند، FedMADE به کیفیت به‌روزرسانی‌ها و میزان سهم آن‌ها در شناسایی حملات اقلیت وزن بیشتری می‌دهد.

۵. محیط آزمایش و ارزیابی (Experimental Evaluation)

۵.۱. مجموعه داده‌ها

نویسندگان از مجموعه داده‌های استاندارد حوزه IoT استفاده کرده‌اند:

- MedBIOt: شامل ترافیک واقعی دستگاه‌های هوشمند خانگی.
- Bot-IoT: متمرکز بر حملات باتنت و شناسایی نفوذ.

۵.۲. سناریوهای آزمایش

آزمایش‌ها در شرایطی انجام شد که داده‌ها به شدت نامتوازن بودند (مثلاً ۹۹٪ داده‌ها نرمال و تنها ۱٪ مربوط به یک حمله خاص بود).

۶. تحلیل نتایج (Results Analysis)

نتایج نشان‌دهنده برتری مطلق FedMADE نسبت به روش‌های سنتی است:

- دقت کلی (Accuracy): به بیش از ۹۸٪ رسید.
- تشخیص حملات اقلیت: در حالی که مدل‌های دیگر در تشخیص حملات نادر نرخ یادآوری (Recall) زیر ۵۰٪ داشتند، FedMADE توانست این نرخ را به بالای ۸۵٪ برساند.
- پایداری: مدل در برابر نویز و سناریوهای Non-IID بسیار مقاوم نشان داد.

۷. بحث و تفسیرپذیری (Discussion)

این بخش توضیح می‌دهد که چگونه FedMADE بار محاسباتی روی دستگاه‌های ضعیف IoT را کاهش می‌دهد. همچنین به اهمیت "تجمع هوشمند" به جای "تجمع ساده" در شبکه‌های توزیع‌شده اشاره می‌کند.

۸. نتیجه‌گیری (Conclusion)

FedMADE با استفاده از تجمع پویا و خوشه‌بندی دستگاه‌ها، چالش ناهمگونی داده در یادگیری فدرال را حل کرده است. این روش حریم خصوصی را حفظ کرده و در عین حال دقت تشخیص نفوذ را در محیط‌های واقعی IoT که داده‌ها نامتوازن هستند، به شدت بهبود می‌بخشد.

۹. مراجع (References)

این مقاله دارای ۴۲ مرجع علمی است که شامل مقالات برتر کنفرانس‌های IEEE INFOCOM و ICLR در حوزه یادگیری ماشین و امنیت شبکه می‌باشد.

پیش‌بینی ترافیک بی‌سیم مبتنی بر ترنسفورمر و بهینه‌سازی شبکه در O-RAN

نویسندگان: محمد عرفات حبیب، پدرو انریکه ایتوری-ریورا و همکاران موسسه: دانشگاه اتاوا و شرکت اریکسون (Ericsson)، کانادا تاریخ: مارس ۲۰۲۴ (پذیرفته شده در ورکشاپ ICC 2024)

۱. چکیده (Abstract)

این مقاله روشی نوآورانه برای پیش‌بینی ترافیک شبکه بی‌سیم در فواصل زمانی کوتاه برای شبکه‌های دسترسی رادیویی باز (O-RAN) با استفاده از معماری ترنسفورمر (Transformer) معرفی می‌کند. سیستم بر اساس ترافیک پیش‌بینی شده، تصمیم می‌گیرد که اپلیکیشن‌های خاصی را فعال کند: یا یک xApp برای هدایت ترافیک (Traffic Steering) جهت بهبود نرخ عبور، و یا یک rApp برای خواب بردن سلول (Cell Sleeping) جهت صرفه‌جویی در انرژی. نتایج شبیه‌سازی نشان می‌دهد که این مکانیزم فعال‌سازی در لحظه (On-demand)، عملکردی معادل سیستم‌های همیشه فعال دارد اما بهر موری منابع را به شدت افزایش می‌دهد.

۲. مقدمه (Introduction)

با ظهور نسل پنجم (5G) و فراتر از آن، شبکه‌ها به سمت باز بودن و هوشمندی حرکت می‌کنند O-RAN. بستری را فراهم می‌کند که در آن توابع شبکه به صورت ماژولار (xApps) و rApps اجرا می‌شوند. چالش اصلی، مدیریت این اپلیکیشن‌ها برای پاسخگویی به نوسانات ناگهانی ترافیک است. پیش‌بینی دقیق ترافیک کلید اصلی برای بهینه‌سازی مصرف انرژی و حفظ کیفیت سرویس (QoS) است.

۳. معماری سیستم و مدل پیشنهادی

۳.۱. مدل پیش‌بینی ترنسفورمر

برخلاف مدل‌های قدیمی مانند LSTM، مدل ترنسفورمر از مکانیزم خود-توجه (Self-Attention) استفاده می‌کند که می‌تواند وابستگی‌های طولانی‌مدت در داده‌های ترافیک شبکه را بهتر شناسایی کند.

- ورودی: داده‌های تاریخی ترافیک (تعداد کاربران، پهنای باند مصرفی).
- خروجی: پیش‌بینی حجم ترافیک برای بازه‌های زمانی آینده.

۳.۲. مدیریت xApp و rApp

سیستم پیشنهادی شامل دو بخش اصلی است:

- Traffic Steering xApp:** وقتی ترافیک سنگین پیش‌بینی می‌شود، این برنامه فعال شده تا بار را بین سلول‌ها تقسیم کند و از احتقان جلوگیری نماید.

2. **Cell Sleeping rApp:** وقتی ترافیک بسیار کم پیش‌بینی می‌شود، سلول‌های اضافی را خاموش می‌کند تا مصرف انرژی کاهش یابد.

۴. مدل‌سازی یادگیری تقویت‌شده (Reinforcement Learning)

برای هدایت ترافیک، از یادگیری تقویت‌شده عمیق (DRL) استفاده شده است. عامل (Agent) در این سیستم یاد می‌گیرد که بر اساس وضعیت لحظه‌ای شبکه (تعداد کاربران و ظرفیت سلول‌ها)، بهترین سلول را برای هر کاربر انتخاب کند تا مجموع نرخ عبور (Throughput) کل شبکه بیشینه شود.

۵. ارزیابی عملکرد و نتایج (Performance Evaluation)

شبیه‌سازی‌ها در یک محیط متراکم شهری با چندین ایستگاه پایه انجام شد.

- **دقت پیش‌بینی:** مدل ترنسفورمر نسبت به مدل‌های خطی و LSTM خطای بسیار کمتری در پیش‌بینی نوسانات ناگهانی نشان داد.
- **بهره‌وری انرژی:** با استفاده از rApp فعال‌شده توسط پیش‌بینی، مصرف انرژی ایستگاه‌های پایه تا ۳۰٪ در ساعات کم‌ترافیک کاهش یافت.
- **نرخ عبور (Throughput):** فعال‌سازی هوشمند xApp توانست نرخ عبور کاربران را در سطحی مشابه با سیستم‌های همیشه روشن نگه دارد، در حالی که منابع پردازشی کمتری مصرف شد.

۶. نتیجه‌گیری (Conclusion)

این مقاله ثابت کرد که استفاده از مدل‌های زبانی بزرگ (مانند ترنسفورمرها) در حوزه مدیریت شبکه (O-RAN) بسیار موثر است. سیستم پیشنهادی با پیش‌بینی هوشمندانه، تعادلی بهینه بین "کارایی شبکه" و "صرفه جویی در انرژی" برقرار می‌کند. این رویکرد گامی مهم به سوی شبکه‌های خودگردان (Autonomous Networks) است.

۷. مراجع (References)

این تحقیق از ۱۵ مرجع کلیدی استفاده کرده است که شامل استانداردهای O-RAN Alliance و مقالات پیشرو در زمینه یادگیری تقویت‌شده و معماری ترنسفورمر در شبکه‌های بی‌سیم می‌باشد.

تشخیص احساسات بر پایه EEG با استفاده از CNN دینامیک چندمقیاسی و ترنسفورمر گیت‌دار (MSDCGTNet)

نویسندگان: ژولینگ چنگ، شوکوی بو و همکاران منبع: مجله Scientific Reports - Nature تاریخ انتشار: دسامبر ۲۰۲۴

۱. چکیده (Abstract)

احساسات نقش حیاتی در فرآیندهای شناختی و تصمیم‌گیری انسان دارند. سیگنال‌های الکتروانسفالوگرافی (EEG) به دلیل رزولوشن زمانی بالا، ابزاری عالی برای تشخیص احساسات هستند. این مقاله یک روش جدید پایان‌به‌پایان (End-to-End) به نام MSDCGTNet را پیشنهاد می‌دهد. این مدل از یک CNN یک‌بعدی دینامیک چندمقیاسی برای استخراج ویژگی‌های پیچیده فضایی و طیفی استفاده می‌کند و سپس از یک ترنسفورمر گیت‌دار (Gated Transformer) برای تثبیت وابستگی‌های سراسری سیگنال بهره می‌برد. ارزیابی‌ها روی مجموعه داده‌های استاندارد (DEAP)، SEED و SEED-IV نشان‌دهنده برتری این مدل نسبت به روش‌های موجود است.

۲. مقدمه (Introduction)

تعامل انسان و کامپیوتر (HCI) با توانایی ماشین در درک احساسات انسان وارد مرحله جدیدی شده است. برخلاف حالات چهره یا تن صدا که قابل کنترل یا پنهان کردن هستند، سیگنال‌های مغزی (EEG) مستقیماً از سیستم عصبی مرکزی منشأ می‌گیرند و بازتاب واقعی‌تری از وضعیت روانی فرد هستند. با این حال، ماهیت غیرایستا و نویز بالای سیگنال‌های EEG، استخراج ویژگی‌های دقیق را دشوار می‌کند که این مقاله با ترکیب CNN و Transformer به آن پاسخ می‌دهد.

۳. معماری مدل پیشنهادی (MSDCGTNet)

مدل از چهار بخش اصلی تشکیل شده است:

- استخراج ویژگی دینامیک: (Multi-Scale Dynamic CNN) این بخش به طور خودکار ویژگی‌های فضایی و فرکانسی را در مقیاس‌های مختلف استخراج می‌کند. استفاده از CNN دینامیک باعث کاهش هزینه‌های محاسباتی نسبت به تبدیل‌های زمان-فرکانس سنتی می‌شود.
- رمزگذار ترنسفورمر گیت‌دار: (Gated Transformer) برای درک روابط بین بخش‌های مختلف سیگنال مغزی در طول زمان. مکانیسم "گیت" باعث می‌شود مدل فقط روی اطلاعات مرتبط تمرکز کند و نویز را فیلتر کند.
- شبکه کانولوشن زمانی: (TCN) برای استخراج ویژگی‌های زمانی عمیق از داده‌های متوالی.

4. ماژول طبقه‌بندی: استفاده از لایه‌های کاملاً متصل (Fully Connected) برای دسته‌بندی احساسات (مثلاً خوشحال، غمگین، عصبانی).

۴. مجموعه داده‌ها و پیش‌پردازش

آزمایش‌ها روی سه پایگاه داده مشهور انجام شد:

- DEAP:** شامل سیگنال‌های مغزی ۳۲ شرکت‌کننده در حال تماشای ویدیوهای احساسی.
- SEED:** تمرکز بر روی سه وضعیت احساسی (مثبت، منفی، خنثی).
- SEED-IV:** بررسی چهار وضعیت احساسی پیچیده‌تر. داده‌ها ابتدا با فیلترهای بالاگذر و پایین‌گذر پیش‌پردازش شدند تا نویزهای محیطی و حرکتی حذف شوند.

۵. نتایج تجربی (Experimental Results)

نتایج نشان داد که مدل MSDCGTNet به دقت‌های زیر دست یافته است:

- مجموعه داده DEAP:** دقت ۹۶.۸٪ در طبقه‌بندی ظرفیت (Valence) و انگیزش (Arousal).
- مجموعه داده SEED:** دقت ۹۸.۲٪ در تشخیص احساسات سه‌گانه.
- این نتایج نشان می‌دهد که ترکیب ویژگی‌های محلی (توسط CNN و ویژگی‌های سراسری) توسط (Transformer) کلید موفقیت در تحلیل سیگنال‌های پیچیده مغزی است.

۶. بحث و تحلیل (Discussion)

تحلیل مدل نشان داد که مکانیسم "توجه (Attention)" در ترنسفورمر، بیشتر روی نواحی فرونتال (پیشانی) و تمپورال (گیجگاهی) مغز تمرکز می‌کند، که از نظر بیولوژیکی با مراکز پردازش احساسات در مغز مطابقت دارد. همچنین حذف هر یک از بخش‌های مدل (CNN) یا (Transformer) باعث افت محسوس دقت شد، که نشان‌دهنده مکمل بودن این دو معماری است.

۷. نتیجه‌گیری (Conclusion)

پژوهش حاضر یک چارچوب قدرتمند برای تشخیص احساسات ارائه داد که می‌تواند در پزشکی (تشخیص افسردگی)، آموزش هوشمند و سیستم‌های سرگرمی مورد استفاده قرار گیرد. نویسندگان قصد دارند در آینده این مدل را برای استفاده در دستگاه‌های EEG پوشیدنی و سبک بهینه‌سازی کنند.

۸. مراجع (References)

این مقاله شامل ۶۵ مرجع علمی است که به کارهای کلیدی در حوزه یادگیری عمیق، پردازش سیگنال و علوم اعصاب استناد کرده است.